

Круглов А.И. БОС-202 ML2

1  $L(\theta) = \sum_{i=1}^n W_i (y_i - x_i^T \theta)^2 \rightarrow \min_{\theta}$ , найти реш. в матричном виде

Пусть  $X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix}$  - матрица признаков,  $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$  - вектор таргетов,  $W = \begin{pmatrix} W_1 & \dots & 0 \\ 0 & \dots & W_n \end{pmatrix}$  - диаг. матрица весов

Тогда в матричном виде:  $L(\theta) = (y - X\theta)^T W (y - X\theta) \rightarrow \min_{\theta}$

$$\frac{\partial L}{\partial \theta} = \left( \frac{\partial}{\partial \theta} (y - X\theta)^T \right) W (y - X\theta) + (y - X\theta)^T W \left( \frac{\partial}{\partial \theta} (y - X\theta) \right) = -X^T W (y - X\theta) + (y - X\theta)^T W (-X) = -2X^T W (y - X\theta)$$

$\min: \frac{\partial L}{\partial \theta} = 0$ , т.е.  $X^T W y = X^T W X \hat{\theta}$ . Выразим  $\hat{\theta} = (X^T W X)^{-1} X^T W y$

По полученной формуле также видно, что МНК - это частный случай при

$W_1 = \dots = W_n = 1$ , т.е.  $\hat{\theta}_{\text{МНК}} = (X^T X)^{-1} X^T y$ , что было на лекции.

Ответ:  $\hat{\theta} = (X^T W X)^{-1} X^T W y$

2  $F(\theta) = -\log L_y(\theta) + \lambda \|\theta\|_2^2 = -\ell_y(\theta) + \lambda \theta^T \theta \Rightarrow \nabla F = -\nabla \ell_y + \nabla (\lambda \theta^T \theta) = -\nabla \ell_y + 2\lambda \theta$

$\nabla \ell_y$  выведен на лекции:  $\nabla \ell_y = X^T (y - S(\theta))$ , где  $S(\theta) = (\sigma(x_1^T \theta), \dots, \sigma(x_n^T \theta))^T$

GD: инициализируем веса  $\theta_0$  и на каждом шаге будем обновлять по правилу:

$$\theta_{t+1} = \theta_t - \eta \nabla F(\theta_t) = \theta_t - \eta (2\lambda \theta_t - X^T (y - S(\theta_t)))$$

(learning rate),  $-\eta \nabla F$  - потому что  $F \rightarrow \min$

SGD: похоже на GD, но каждый шаг зависит от батча  $I = \{i_1, \dots, i_m\} \in \mathcal{U}\{1, \dots, n\}$ :

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{1}{m} (-X_I^T (y_I - S(\theta_t))) - \eta \cdot 2\lambda \theta_t$$

IRLS: задаем начальные веса  $\theta_0$  и будем их обновлять. На каждом шаге вычисляем

$$W = \text{diag}(\sigma(x^T \theta)(1 - \sigma(x^T \theta))) \text{ и } \theta_{t+1} = \theta_t - (X^T W(\theta_t) X)^{-1} (-X^T (y - S(\theta_t))),$$

что подробнее выводится на лекции

Градиентный спуск хорошо работает для малых объемов данных, т.к. требует много вычислений. Поэтому на практике чаще обращаются к SGD или IRLS