

### ЗАДАЧА 3, Круглов А.И. БО5-207

#### 1) $\hat{\theta}$ в ridge-регрессии

Вспомним сведения о матр. производной с лекции:

$$f(x) = a^T x \Rightarrow \nabla f = a, \quad f(x) = x^T A x \Rightarrow \nabla f = (A + A^T) x$$

$$\begin{aligned} \text{Оптимизируем функционал } F(\theta) &= \|Y - X\theta\|^2 + \lambda \|\theta\|^2 = \\ &= (Y - X\theta)^T (Y - X\theta) + \lambda \theta^T \theta = Y^T Y - 2(Y^T X)\theta + \theta^T \cdot \\ &\cdot (X^T X + \lambda E)\theta; \text{ отметим, что } (X^T X + \lambda E)^T = (X^T X + \lambda E). \end{aligned}$$

$$\text{Тогда } \nabla F(\theta) = -2X^T Y + 2(X^T X + \lambda E)\theta = 0, \text{ откуда}$$

$$X^T Y = (X^T X + \lambda E)\theta \Rightarrow \hat{\theta} = (X^T X + \lambda E)^{-1} X^T Y.$$

В МНК было  $\hat{\theta} = (X^T X)^{-1} X^T Y$ , а слагаемое  $\lambda E$  может сделать матрицу невырожденной (обратимой), тривиальный пример:  $X^T X = 0$ ,  $\det(X^T X) = 0$ ,  $\det(X^T X + \lambda E) = \det(\lambda E) \neq 0$

#### 2) шаг град. спуска

$$\text{GD: } \theta_{t+1} = \theta_t - \eta \nabla F(\theta) \Rightarrow \theta_{t+1} = \theta_t + \eta (X^T Y - (X^T X + \lambda E)\theta_t)$$

$$\begin{aligned} \text{SGD: тоже, но берем только строки с номерами из } I \text{ (} I = \\ = \{i_1, \dots, i_K\}, i_1, \dots, i_K \sim U\{1, \dots, n\} \text{ - бачи)}, \text{ т.е. } \theta_{t+1} = \theta_t + \eta \frac{n}{K} \cdot \\ \cdot (X_I^T Y_I - (X_I^T Y_I + \lambda E)\theta_t) \end{aligned}$$

#### 3) если признаки не приведены к одинаковому масштабу, то

штраф за величины весов применяется к весам "нестабельно",

нормально. Стандартизация позволяет привести столбцы к равной



масштабу (по сути, избавившись от размерности и оставить  
только информацию о распределении признака), из-за чего  
ridge-регрессия работает заметно лучше.